
Detección de deforestación en Perú con U-Net

Detección de cambio (*before/after*) sobre imágenes Sentinel-2

Andres Flores

Unidad de Posgrado - FIIS
Universidad Nacional de Ingeniería
affloresb@uni.pe

Victor Lazo

Unidad de Posgrado - FIIS
Universidad Nacional de Ingeniería
vlazop@uni.pe

Rubén López

Unidad de Posgrado - FIIS
Universidad Nacional de Ingeniería
ruben.lopez.m@uni.pe

Juan Quispe

Unidad de Posgrado - FIIS
Universidad Nacional de Ingeniería
juan.quispe.h@uni.pe

Abstract

Se aborda la detección de deforestación en la Amazonía peruana sobre imágenes Sentinel-2, usando como etiquetas los polígonos oficiales de SERFOR. El análisis muestra que dichas etiquetas representan **detección de cambio de un período** (con fechas de inicio y fin), por lo que el problema se modela con un par de imágenes *antes/después* y una U-Net con encoder ResNet34. A través de un estudio de ablación controlado se evalúan el tamaño del encoder, el uso de NDVI, la función de pérdida y el balance de clases. La mejor configuración (ResNet34, 8 canales, pérdida Dice + BCE con `pos_weight` balanceado) alcanza un **IoU de 0,413 y F1 de 0,584** sobre el conjunto de prueba. El mayor impacto provino del balance de clases, no de la arquitectura; el límite restante está en la precisión de las etiquetas de referencia.

1. Problema y enfoque

El objetivo es detectar deforestación en la Amazonía peruana sobre imágenes Sentinel-2, usando como etiquetas los polígonos oficiales de **SERFOR** (`deforestacion.geojson`, 9.910 polígonos).

El hallazgo clave del análisis inicial es que las etiquetas SERFOR **no marcan todo el suelo desnudo**, sino la **deforestación ocurrida en un período específico**. Cada polígono trae dos fechas, FESATA (antes) y FESATB (después), y señala solo el cambio entre ellas. Por eso el problema es de **detección de cambio**, no de segmentación sobre una sola imagen.

Con una sola imagen el modelo no puede distinguir un clareo nuevo de uno antiguo (ambos son suelo desnudo). La solución fue usar un **par de imágenes** del mismo lugar: una *antes* (cercana a FESATA, bosque en pie) y otra *después* (cercana a FESATB, ya clareado). El modelo aprende el cambio verde→café, que es exactamente lo que marca el polígono.

2. Pipeline

Mejora de etiquetas: curador web

Las etiquetas SERFOR no siempre son precisas (bordes aproximados, deforestación faltante o mal delimitada). Para mejorarlas se desarrolló un **curador web** con dos vistas sincronizadas *antes/des-*

Notebook	Función
01_descarga_y_exploracion	Carga y exploración de las etiquetas SERFOR.
02_descarga_sentinel2	Descarga el par <i>antes/después</i> (Sentinel-2 L2A vía STAC earth-search), bandas R, G, B, NIR a 10 m. Filtra por nubes y solapamiento; descarga en paralelo.
03_generar_mascaras	Rasteriza los polígonos sobre la grilla de la imagen. Filtra por la ventana temporal del par y suma anotaciones manuales del curador web.
04_dataset_parches	Empareja imágenes y máscaras; separa train/val/test <i>por escena</i> (sin fuga de datos).
05_modelo_unet	Entrena la U-Net.

pués, disponible en <https://deforestacion-peru.cloud4geo.com/> (Figura 1). La herramienta permite, por cada par: (i) revisar visualmente el cambio y aceptar o descartar el par (*Keep/Reject*); y (ii) cuando falta deforestación en la etiqueta, **agregar los segmentos faltantes a mano**, ya sea dibujando el polígono o con una **varita mágica** (selección por color sobre la imagen real). Las anotaciones exportadas se suman a los polígonos SERFOR en el notebook 03, mejorando la calidad de las máscaras de entrenamiento.



Figura 1: Curador web *before/after* (<https://deforestacion-peru.cloud4geo.com/>). Izquierda y centro: imágenes Sentinel *antes* y *después* sincronizadas, con los polígonos SERFOR superpuestos. Donde la etiqueta no cubre todo el cambio, se añaden segmentos con las herramientas de dibujo o de varita mágica (barra inferior). El panel derecho gestiona la revisión y la exportación de la curación y las anotaciones.

3. Datos

- **1.039 pares** tras curación: **727 train / 156 val / 156 test**.
- Separación **por escena Sentinel**: recortes de la misma escena no caen en train y test a la vez (sin fuga de datos).
- Entrada base: **8 canales** = R, G, B, NIR (antes) + R, G, B, NIR (después), normalizados a $[0, 1]$, redimensionados a 128×128 .
- Clase positiva (deforestación) cercana al 2,9 % de los píxeles: fuerte desbalance.

4. Modelo y entrenamiento

- **U-Net** con encoder **ResNet34** pre-entrenado en ImageNet (transfer learning); el primer conv se adapta a 8 canales.
- **Pérdida = Dice + BCE** con `pos_weight` para el desbalance.
- Optimizador Adam ($1r=1e-3$) + *scheduler* que reduce el LR cuando el IoU de validación se estanca.
- Se guardan los pesos del **mejor IoU de validación**.
- Métricas sobre la clase deforestación: **IoU y F1** (no *accuracy*, que engaña con clases desbalanceadas). Se reporta también el mejor umbral del barrido.

5. Experimentos y resultados

La métrica principal es el **IoU en test** sobre la clase deforestación. Como el umbral 0,5 no es óptimo con clases desbalanceadas, se reporta también el mejor umbral del barrido (en general 0,7).

Experimento	Encoder	Can.	Ep.	IoU val	IoU@0.5	IoU@mej.	F1@mej.
r34 + pw_sqrt *	ResNet34	8	100	0,397	0,411	0,413	0,584
r18 + pw_sqrt	ResNet18	8	100	0,391	0,385	0,387	0,558
r34 + 8band	ResNet34	8	100	0,337	0,360	0,381	0,552
r34 + 8band (150 ep)	ResNet34	8	150	0,332	0,345	0,367	0,537
r34 + lovász	ResNet34	8	100	0,348	0,360	0,360	0,530
r34 + ndvi11	ResNet34	11	150	0,316	0,312	0,347	0,516
r50 + ndvi11	ResNet50	11	150	0,326	0,299	0,327	0,492

Tabla 1: Resultados de los experimentos. pw_sqrt: pos_weight reducido a la raíz de neg/pos ($\approx 5,8$); ndvi11: 8 canales + NDVI antes, NDVI después y Δ -NDVI; lovász: pérdida BCE + Lovász.

Mejor modelo: ResNet34 + 8 bandas + 100 epochs + pos_weight balanceado $\rightarrow$ IoU 0,413, F1 0,584 (umbral 0,7). Con el pos_weight balanceado la precisión sube de 0,40 a 0,51 y el recall baja de 0,77 a 0,67 (modelo más equilibrado), y el IoU queda casi plano entre umbrales (0,403–0,413), señal de buena calibración.




Figura 2: Comparación del IoU en test (mejor umbral) entre los siete experimentos. El balance del pos_weight sobre ResNet34 con 8 bandas (verde) da el mejor resultado; agregar NDVI o usar ResNet50 lo empeora.




Figura 3: Curvas de entrenamiento del mejor modelo (ResNet34 + 8 bandas + pos_weight balanceado). Izquierda: pérdida de entrenamiento y validación. Derecha: IoU y F1 de validación, que se estabilizan alrededor de la época 55–90.

6. Por qué cada ajuste funcionó o no

El estudio se hizo cambiando **una variable a la vez** sobre la mejor configuración del momento, para atribuir cada subida o bajada a una causa concreta.

Before/after (8 canales) — la base. Pasar de una sola imagen a un par antes/después fue el cambio que habilitó el proyecto. Con una imagen el modelo no puede distinguir un clareo nuevo de uno antiguo; con el par sí ve el cambio.

NDVI como bandas extra (11 canales) — no ayudó ($0,413 \rightarrow 0,347$). El NDVI se calcula como $(NIR - R)/(NIR + R)$. La red ya tiene las bandas R y NIR de ambas fechas y puede derivar el NDVI por su cuenta, así que darlo explícito no agrega información nueva; solo añade 3 canales con pesos iniciales aleatorios (ruido). Con pocos datos, ese ruido perjudica.

ResNet50 (encoder más grande) — empeoró ($0,413 \rightarrow 0,327$). ResNet50 (~ 32 M parámetros) tiene más capacidad que ResNet34 (~ 24 M), pero también más capacidad de **memorizar**. Está pensada para conjuntos grandes (decenas o cientos de miles de imágenes). Con solo 727 imágenes de entrenamiento, el modelo grande no aprende el patrón general: **memoriza el conjunto de train** (sobreajuste) y rinde peor en test.

ResNet18 (encoder más chico) — un poco peor ($0,413 \rightarrow 0,387$). Por la misma lógica se probó ResNet18 (~ 14 M) buscando menos sobreajuste, pero quedó por debajo: con menos parámetros el modelo se queda corto (subajuste). Junto con ResNet50 se forma una **U invertida**: ni muy grande (memoriza) ni muy chico (no alcanza). **ResNet34 es el punto de equilibrio** entre capacidad y cantidad de datos.

pos_weight balanceado — la mejora más grande ($0,381 \rightarrow 0,413$). El pos_weight del BCE controla cuánto se castiga perder un píxel de deforestación (clase rara, cercana al 2,9 %). El valor por defecto neg/pos $\approx 33,6$ castiga tanto perder un positivo que el modelo **marca de más** (recall 0,77 pero precisión 0,40). Bajarlo a la raíz ($\approx 5,8$) lo equilibra (precisión 0,51, recall 0,67) y sube el IoU a 0,413. Fue el ajuste de mayor impacto y atacó el **desbalance de clases**, el problema real.

Lovász loss — no ayudó y descalibró ($0,413 \rightarrow 0,360$). La Lovász optimiza el IoU de forma directa (aproximación diferenciable), pero en la práctica rindió peor y **rompió la calibración**: empuja las probabilidades a valores extremos, así que el modelo solo funciona con umbral 0,5 exacto (a 0,6 ya casi no predice). Dice + BCE resultó más robusto.

Número de epochs — 100 es suficiente. Comparando 150 vs 100 epochs el resultado es equivalente (diferencias dentro del ruido). El IoU de validación se estabiliza alrededor de la época 55–90.

7. Conclusiones del estudio de ablación

1. **El balance del `pos_weight` tuvo el mayor impacto** (+0,03 IoU), atacando el desbalance de clases en lugar de la arquitectura.
2. **El tamaño del encoder tiene un óptimo claro en ResNet34** (U invertida: $R18\ 0,387 < R34\ 0,413 > R50\ 0,327$).
3. **Las features derivadas (NDVI) no ayudan**: la red ya las deriva de R y NIR.
4. **100 epochs son suficientes** (convergencia $\sim$ época 55–90).
5. **El modelo final está bien calibrado**: IoU casi constante entre umbrales.
6. **El techo restante está en las etiquetas**: tras agotar las palancas de modelado, el límite proviene de la imprecisión de los polígonos de referencia SERFOR. Mejorar las etiquetas es la vía con mayor recorrido pendiente.

8. Valoración del resultado

Un IoU de $\sim 0,41$ (F1 0,58) es **razonable** para detección de cambio de deforestación con etiquetas de referencia gruesas, imágenes a 10 m y un conjunto de datos pequeño.

Comparación con la literatura. Torres et al. [2021] evalúan U-Net y variantes para detección de deforestación en la Amazonía brasileña con Landsat-8 y Sentinel-2 (parches 128×128 , igual que este trabajo), usando como referencia el mapa oficial PRODES. Su mejor red (ResU-Net) reporta sobre Sentinel-2 un **F1 de 70,2 %** frente a la referencia sin auditar, que sube a **78,0 %** tras una auditoría manual del mapa de referencia (en F1 equivale a un IoU aproximado de 0,54–0,64). Nuestro modelo (F1 0,58, IoU 0,41) queda por debajo, lo cual es esperable: dicho estudio dispone de cobertura de toda la Amazonía y de la referencia profesional PRODES, frente a las 727 muestras de entrenamiento y las etiquetas SERFOR de Perú de este trabajo. Aun así, el resultado se sitúa en un rango comparable.

Refuerzo del hallazgo principal. El propio trabajo de Torres et al. [2021] advierte que el mapa de referencia PRODES se delinea manualmente a escala 1/75.000 y que asumir que la referencia representa la verdad absoluta a nivel de píxel lleva a subestimar las métricas de exactitud, exactamente la limitación observada con las etiquetas SERFOR. De hecho, su F1 mejora de 70 % a 78 % solo con auditar (mejorar) las etiquetas de referencia, sin cambiar el modelo (Figura 4), lo que confirma que la calidad de las etiquetas es el factor limitante.




Figura 4: Comparación referencial del F1-score con Torres et al. [2021] sobre Sentinel-2. La comparación es *cualitativa*: los conjuntos de datos y mapas de referencia son distintos (SERFOR-Perú vs PRODES-Brasil). El salto de 0,702 a 0,780 en ese estudio se obtiene únicamente auditando las etiquetas de referencia, sin cambiar el modelo, lo que evidencia el efecto de la calidad de las etiquetas sobre la métrica.

La inspección visual confirma que el modelo localiza la deforestación real, incluso donde el polígono de referencia es impreciso. Un IoU de 0,8 corresponde a tareas con bordes nítidos y etiquetas precisas, que no es el caso aquí.

9. Trabajo futuro

La vía con mayor impacto esperado es **mejorar las etiquetas**, no la arquitectura:

- Ampliar las **anotaciones manuales** (curador web) para corregir y completar los polígonos donde SERFOR falla.
- Incorporar **más pares** al conjunto de datos.
- Probar **funciones de pérdida** específicas para desbalance (Tversky, Focal).
- **Análisis de errores**: revisar las escenas de test con peor IoU (suelen ser nubes o bordes mal delimitados).

Referencias

Matthew C. Hansen, Peter V. Potapov, Rebecca Moore, Matt Hancher, S. A. Turubanova, Alexandra Tyukavina, David Thau, S. V. Stehman, S. J. Goetz, T. R. Loveland, et al. High-resolution global maps of 21st-century forest cover change. *Science*, 342(6160):850–853, 2013. doi: 10.1126/science.1244693.

Mabel Ortega Adarme, Raul Queiroz Feitosa, Patrick Nigri Happ, Claudio Aparecido De Almeida, and Alessandra Rodrigues Gomes. Evaluation of deep learning techniques for deforestation detection in the brazilian amazon and cerrado biomes from remote sensing imagery. *Remote Sensing*, 12(6): 910, 2020. doi: 10.3390/rs12060910. URL <https://www.mdpi.com/2072-4292/12/6/910>.

Daliana Lobo Torres, Javier Noa Turnes, Pedro Juan Soto Vega, Raul Queiroz Feitosa, Daikson Esteban Silva, José Marcato Junior, and Claudio Almeida. Deforestation detection with fully convolutional networks in the amazon forest from landsat-8 and sentinel-2 images. *Remote Sensing*, 13(24):5084, 2021. doi: 10.3390/rs13245084. URL <https://www.mdpi.com/2072-4292/13/24/5084>.

Artefactos por experimento en `data/experiments/<nombre>/` (checkpoint, curvas, `metrics.json`); tabla acumulada en `data/experiments/results.csv`.